

Lista Prática: Métodos Iterativos para Sistemas Lineares e Aplicação de Decomposições Matriciais

1) Crie algoritmos em Python para os métodos de Jacobi e Gauss-Seidel, e resolva os sistemas lineares abaixo:

a. $3x_1 - x_2 + x_3 = 1,$
 $3x_1 + 6x_2 + 2x_3 = 0,$
 $3x_1 + 3x_2 + 7x_3 = 4.$

b. $10x_1 - x_2 = 9,$
 $-x_1 + 10x_2 - 2x_3 = 7,$
 $-2x_2 + 10x_3 = 6.$

c. $10x_1 + 5x_2 = 6,$
 $5x_1 + 10x_2 - 4x_3 = 25,$
 $-4x_2 + 8x_3 - x_4 = -11,$
 $-x_3 + 5x_4 = -11.$

d. $4x_1 + x_2 - x_3 + x_4 = -2,$
 $x_1 + 4x_2 - x_3 - x_4 = -1,$
 $-x_1 - x_2 + 5x_3 + x_4 = 0,$
 $x_1 - x_2 + x_3 + 3x_4 = 1.$

e. $4x_1 + x_2 + x_3 + x_5 = 6,$
 $-x_1 - 3x_2 + x_3 + x_4 = 6,$
 $2x_1 + x_2 + 5x_3 - x_4 - x_5 = 6,$
 $-x_1 - x_2 - x_3 + 4x_4 = 6,$
 $2x_2 - x_3 + x_4 + 4x_5 = 6.$

f. $4x_1 - x_2 - x_4 = 0,$
 $-x_1 + 4x_2 - x_3 - x_5 = 5,$
 $-x_2 + 4x_3 - x_6 = 0,$
 $-x_1 + 4x_4 - x_5 = 6,$
 $-x_2 - x_4 + 4x_5 - x_6 = -2,$
 $-x_3 - x_5 + 4x_6 = 6.$

Use o vetor chute inicial como $x^{(0)} = 0$, ou seja, um vetor com todas as componentes iguais a zero, e uma tolerância para o erro de 10^{-3} . Para cada sistema linear, crie uma tabela mostrando para os dois métodos o valor da solução do sistema, do erro e o número de iterações utilizadas.

2) Use o código abaixo para gerar 6 matrizes de tamanho n , com n à sua escolha (n escolhido deve ser maior que 10).

```
def gerarMatrix(n):  
    x = np.linspace(0,1, n)  
    x_, y_ = np.meshgrid(x, x)  
    A = (2*n * np.random.rand(n,n))/(n**(2.6)*(x_ - y_)**2 + 1)  
    return A
```

Gere o vetor independente b , assumindo que todos os sistemas criados terão o vetor solução $x = 1$ (vetor preenchido de 1's) como resposta. Use os métodos de Jacobi e Gauss-Seidel implementados no exercício 1) para resolver os sistemas lineares. Use o vetor chute inicial como $x^{(0)} = 0$, e uma tolerância

para o erro de 10^{-3} . Para cada sistema linear, crie uma tabela mostrando para os dois métodos, o erro e o número de iterações utilizadas, ou caso a matriz gerada não for ideal para os métodos (resultado não convergir), verificar a condição desrespeitada pela matriz e registrar na tabela também a falha.

3) Instruções para o exercício:

1. Decompor uma matriz usando decomposição SVD do pacote `numpy.linalg` (`numpy.linalg.svd`)
 - 1.1 Entender como recompor as matrizes decompostas
 - 1.2 Verificar como podemos reduzir as dimensões das matrizes e mesmo assim obter uma matriz resultante de mesma dimensão original. $A_{m \times n} = U_{m \times m} \Sigma_{m \times n} V_{n \times n}^T$
2. Carregar uma imagem no formato `numpy.array` usando python (carregar em escala cinza)
3. Aplicar o conceito do item 1. Na imagem carregada.
4. Analisar a relação entre o n escolhido, qualidade final (comparação visual e numérica), e a taxa de compressão (valores a serem armazenados no formato original e depois de aplicar o método),
5. Aplicar em uma imagem de baixa resolução (<300p) e em uma de alta resolução (>HD)

Sugestões para o exercício 3):

- A biblioteca **cv2** já instalada no GoogleColab carrega imagens em formato `numpy`
- O comando `sys.getsizeof()` da biblioteca `sys` calcula o tamanho em memória(Ram) de um objeto.